

Name: Hifza Majeed

Roll No: 19P-1652

Section: BS(SE) 8A

Assignment No 1

Tokenization and segmentation

Introduction

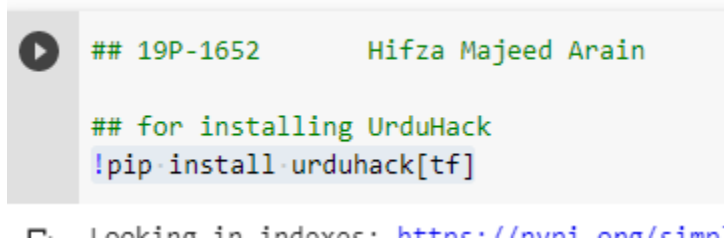
The language I worked with for this project was Urdu, and I separated words and sentences from passages.

Steps to solve the Problem

Step: 1

To install the Urdu hack and import the Urdu hack.

Install the urdu hack through `!pip install urduhack[tf]`.

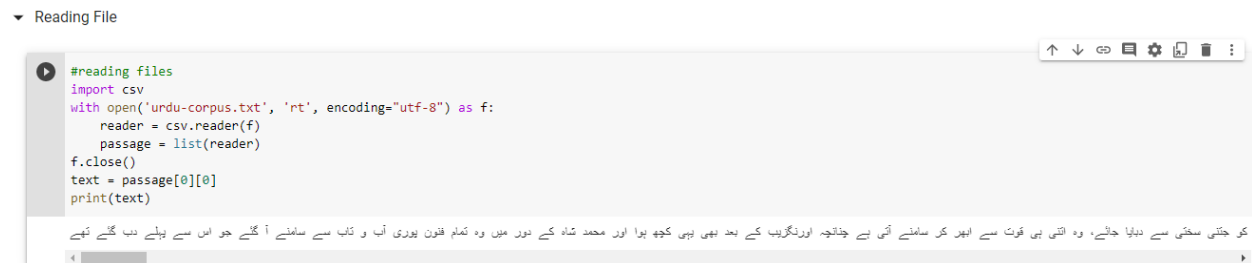


```
## 19P-1652      Hifza Majeed Arain

## for installing UrduHack
!pip install urduhack[tf]
```

Step: 2

Reading file:



```
#reading files
import csv
with open('urdu-corpus.txt', 'rt', encoding="utf-8") as f:
    reader = csv.reader(f)
    passage = list(reader)
f.close()
text = passage[0][0]
print(text)
```

کو جتنی سخی سے دیکھا جائے، وہ اتنی ہی قوت سے ابھر کر سامنے آتی ہے چنانچہ اورنگزیب کے بعد بھی کچھ پورا اور محمد شاہ کے دور میں وہ تمام فنون پوری آب و تاب سے سامنے آ گئے جو اس سے پہلے دب گئے تھے

Step: 3

Split full string into list of char

We splits the paragraph into the words.

```
#split full string into list of char.
tex= ['ہیں', 'انہا', 'گیا', 'جاسکے', 'گئیں', 'رہے', 'گئے', 'تھے', 'دیا', 'ہیں', 'ہے'] #ending words in urdu .....
list_of_string= tex.split() # string split into list
print(list_of_string) # print the list
```

['تمام', 'فون', 'یوری', 'آب', 'و', 'آب', 'سے', 'سے', 'سامنے', 'آ', 'گئے', 'جو', 'اس', 'سے', 'پلے', 'دب', 'گئے', 'تھے', 'سب', 'اچھے', 'حفاظ', 'کی', 'قر', 'نرا', 'گری', 'کھینا']

Step: 4

Adding the ‘-’ at the end of sentences

we are comparing the paragraph with end sentences word list than add the ‘-’ at end of sentences .

```
for i in range(len(list_of_string)): # start array / list from starting element to last
    #print(list_of_string[i])
    for j in range(len(tex)): # ending loop from start element to last
        #print(tex[j])
        if(list_of_string[i]==tex[j]): # if matched array one and array two...
            #print( list_of_string[i] )
            list_of_string.insert(i+1, '-') # adding "-" here
    print(list_of_string)
```

['گرسنہ', 'کی', 'سالوں', 'سے', 'مختلف', 'بحران', 'آئے', 'جائے', 'رہے', '-', 'لیکن', 'حالیہ', 'آقا', '،', 'چینی', 'سمیت', 'دیگر', 'بحران', 'اجتک', 'پید']

Step: 5

Words tokenization

in list of string having all the word just we apply the loop on the list of string and print the words

```
#words segmentations .....
```

```
for words in list_of_string: # loop from array of list  
    print(words)
```

گزشتہ
کئی
سالوں
سے
مختلف
بحران
آئے
جائے
ہے
-
لیکن
حالیہ
آٹا
،
چینی
سمیت
دیگر

Step: 6

Sentences tokenization

```
[11] #sentence segmentations .....  
null_string = '' # null string  
for i in list_of_string: # loop from array of list  
    #if(list_of_string=='-'):  
    null_string += ' ' + i # convert into string
```

```
print(null_string)
```

گزشتہ کئی سالوں سے مختلف بحران آئے جائے رہے - لیکن حالیہ آٹا ، چینی سمیت دیگر بحران اچانک پیدا ہوئے اور ان پر جسے آئی ٹی تشکیل دے دیں گئیں - تاکہ عوام کو ریلیف دیا - جا